

MÓDULO 7: INFRAESTRUCTURA Y CLOUD

OBSERVABILIDAD EN EL MUNDO DE LOS LLMS

LLMOps

BIG school

GENERAMOS
NEGOCIO

BIGSEO

Observabilidad en el mundo de los LLMs

Definición

- **DevOps para modelos de lenguaje**
 - Conjunto de prácticas y herramientas para gestionar el ciclo de vida completo de aplicaciones basadas en LLMs, desde desarrollo hasta producción.
- **Gestión de prompts y versionado**
 - Control de versiones de prompts, templates y configuraciones de modelos, permitiendo rollbacks y experimentación controlada.
- **Monitoreo y observabilidad**
 - Seguimiento en tiempo real de métricas como latencia, costes, calidad de respuestas y detección de anomalías en el comportamiento del modelo.
- **Pipelines de evaluación y despliegue**
 - Automatización de pruebas, evaluaciones de seguridad, y despliegues graduales para garantizar la calidad y confiabilidad de las aplicaciones LLM en producción.

Objetivos

- Reliability en producción
- Optimizar el Performance
- Eficiencia de costes
- Calidad en la inferencia

MÓDULO 7: INFRAESTRUCTURA Y CLOUD

INTRODUCCIÓN A LANGSMITH

LLMOps

BIG school

GENERAMOS
NEGOCIO

BIGSEO

Introducción a LangSmith



¿Qué es LangSmith?

- **Herramienta cloud para:**
 - Monitorización de las llamadas a LLMs
 - Debugging de cadenas(Chains)
 - Monitorización del performance
 - Monitorización de Costes
 - Evaluar la calidad



Configuración


```
import os
```

```
os.environ["LANGCHAIN_TRACING_V2"] = "true"  
os.environ["LANGCHAIN_API_KEY"] = "your-api-key"  
os.environ["LANGCHAIN_PROJECT"] = "my-project"
```



Introducción a LangSmith

📊 ¿Qué es LangSmith?



Introducción a LangSmith



Gestión de Prompts

- Control de versiones de prompts
- A/B testing de variantes
- Edición colaborativa de prompts
- Deployment tracking
- Comparar performance respecto a otras versiones



Workflow

- Crear un prompt en LangSmith
- Testear diferentes versiones
- Desplegar en producción
- Monitorizar performance
- Iterar basándonos en los valores de la monitorización



MÓDULO 7: INFRAESTRUCTURA Y CLOUD

¿QUÉ SON LAS EVALUATIONS?

LLMOps

BIG school

GENERAMOS
NEGOCIO

BIGSEO

¿Qué son las evaluations?

¿Qué son?

- Pruebas sistemáticas para evaluar la calidad, precisión y capacidades de los modelos de lenguaje en tareas específicas como comprensión, generación y razonamiento.

Tipos de Evaluación

- Correctness - ¿Es correcta la respuesta?
- Relevancia - ¿Es relevante al contexto?
- Coherencia - ¿Es coherente y lógica?
- Conciseness - ¿Es concisa?

LLM-as-a-Judge

- Usar LLMs para evaluar otros LLMs:
 - LLM como evaluador
 - Criterios específicos
 - Scoring consistente

MÓDULO 7: INFRAESTRUCTURA Y CLOUD

CONCLUSIONES

LLMOps

BIG school

GENERAMOS
NEGOCIO

BIGSEO

Conclusiones

Beneficios LLMOps

- Reliability en producción
- Ayuda a mantener la calidad del producto
- Optimización de costes
- Monitorización del performance
- Mejora Continua

Métricas Importantes

- Latencia - Tiempos de respuesta
- Throughput - LLamadas/segundo
- Costes - Uso de tokens
- Calidad - Evaluaciones
- Uptime - Availability