


MÓDULO 11: MASTERCLASS

¿CÓMO EVALUAR LLMS?

BIG school

GENERAMOS
NEGOCIO

BIGSEO



¿Cómo
evaluar
LLMs?

BIG school

Índice

Large Models

Entrenamiento de modelos

Datasets de evaluación

Métricas de evaluación




Large Models

BIG school


Large Models

La arquitectura de Transformers cambió la forma en la que procesamos la información ya que a diferencia de las RNN/LSTM/GRU, procesan toda la secuencia en paralelo en vez de palabra por palabra.



Large Models

La auto-atención (self-attention) permite al modelo analizar otras palabra en una secuencia para entender el contexto de la palabra que está analizando el transformer.



Large Models

Las diferentes arquitecturas basadas en transformers han dado lugar a tres tipos de modelos base.

Encoder-only

BERT

Compresión
Clasificación

Decoder-only

GPT

Generación
Traducción

Encoder-Decoder

T5/BART

Traducción
Resumen

Large Models

Los modelos genéricos son muy complejos para resolver tareas específicas y debemos especializarnos mediante entrenamiento o prompting.

Pre-Training

Proceso de aprendizaje masivo autosupervisado sobre conjuntos de datos masivos procedentes de Internet.

Large Models

Los modelos genéricos son muy complejos para resolver tareas específicas y debemos especializarnos mediante entrenamiento o prompting.



Proceso de entrenamiento (ajuste) sobre un dataset de pequeño tamaño con contenido ultra-especializado (programación en python).

Large Models


Los modelos genéricos son muy complejos para resolver tareas específicas y debemos especializarnos mediante entrenamiento o prompting.



Proceso de alineamiento basado en retroalimentación humana orientado a que el modelo actúe de forma útil, honesta y segura.

Large Models

Tenemos diferentes tipos de modelos de tipo cerrado (SaaS) o de tipo abierto (Open weights).





Entrenamiento de modelos

BIG school

Entrenamiento de modelos

Los LLMs (Large Language Models) y los LVMs (Large Vision Models) son modelos de inteligencia artificial a gran escala diseñados para **comprender, generar y razonar sobre información compleja** a partir de datos textuales y visuales.

Entrenamiento de modelos

Pre-Training

(Computationally Expensive)




Large
Unlabeled Corpus

El **pre-entrenamiento** consiste en entrenar un modelo en un conjunto de datos masivo (corpus de texto) para que aprenda los patrones generales del lenguaje, representaciones de palabras, relaciones semánticas, entre otros aspectos.


Este tipo de modelos se denominan modelos fundacionales.

Entrenamiento de modelos




El **ajuste fino** (o *fine-tuning*) consiste en adaptar el modelo pre-entrenado a una tarea específica, como el análisis de sentimientos, la programación o la traducción automática, utilizando un conjunto de datos más pequeño y especializado en dicha tarea.

Entrenamiento de modelos



El P-tuning (ajuste basado en prompts) consiste en proporcionar instrucciones específicas de la tarea (prompts) al modelo durante el proceso de ajuste fino. Estos prompts sirven como pistas o directrices para que el modelo genere el resultado deseado para una tarea en particular.

Entrenamiento de modelos



El ajuste por adaptadores (Adapter-tuning) consiste en añadir pequeñas capas de adaptación específicas para una tarea al modelo pre-entrenado. Estas capas pueden entrenarse con unos pocos ejemplos para mejorar el rendimiento en esa tarea específica.

Si quieres crear tu propio
modelo para tu propio tarea

Debes crear tu
propio **benchmark**



Datasets de evaluación

BIG school

BIGSEIO

GENERAMOS
NEGOCIO

Datasets de Evaluación

Uno de los grandes problemas de los modelos largos es que los utilizamos para todo pero no tenemos claro cómo evaluar sus respuestas para nuestros casos específicos.

Tenemos datasets de evaluación estándar de tareas:

- Conocimiento general.
- Razonamiento lógico y matemático.
- Programación.

Datasets de Evaluación

MMLU (Massive Multitask Language Understanding) es un dataset de evaluación de contenidos de cultura general para la IA, ya que permite evaluar su desempeño en 57 materias que abarcan STEM, ciencias sociales, humanidades y otras áreas del conocimiento.

```
{ 'question': 'What is true for a type-Ia ("type one-a") supernova?',  
  'subject': 'astronomy',  
  'choices': [  
    'This type occurs in binary systems.',  
    'This type occurs in young galaxies.',  
    'This type produces gamma-ray bursts.',  
    'This type produces high amounts of X-rays.'],  
  'answer': 0}
```

BIG school

Incluye nivel básica hasta nivel profesional experto.

Datasets de Evaluación

El GSM8K (Grade School Math 8K) es un dataset de evaluación diseñado de resolución de problemas matemáticos multi-paso mediante el razonamiento lógico secuencial, exigiendo que el modelo no solo dé la respuesta correcta, sino que siga una cadena de razonamiento coherente para llegar a ella.

```
{ "question": "A robe takes 2 bolts of blue fiber and half that much white fiber.  
How many bolts in total does it take?",  
  "answer": "It takes  $2 \div 2 = 1$  bolt of white fiber\nSo the total amount  
of fabric is  $2 + 1 = 3$  bolts of fabric\n#### 3" }
```

Datasets de Evaluación

HumanEval es un dataset de evaluación diseñado por OpenAI para medir la capacidad de los modelos de IA en la generación de código y la resolución de problemas de programación de forma autónoma.

```
{
  "task_id": "HumanEval/999",
  "prompt": "def reverse_string(s: str) -> str:\n \"\"\" Devuelve la cadena invertida.\n >>>
reverse_string('hola')\n 'aloh'\n \"\"\"\",
  "entry_point": "reverse_string",
  "canonical_solution": " return s[::-1]",
  "test": "def check(candidate):\n assert candidate('abc') == 'cba'\n assert candidate('')
== '\n assert candidate('ai') == 'ia'\n }
```

Datasets de Evaluación

El MBPP (Mostly Basic Python Problems) es un dataset de evaluación compuesto por aproximadamente 1,000 problemas de programación de nivel básico, diseñados para evaluar la capacidad de los modelos de IA para convertir descripciones en lenguaje natural en código Python ejecutable y funcional.

```
{
  "task_id": 11,
  "text": "Write a python function to remove first and last occurrence of a given character from the string.",
  "code": "def remove_Occ(s,ch): \r\n    for i in range(len(s)): \r\n        if (s[i] == ch): \r\n            s = s[0 : i] + \r\ns[i + 1 : len(s)] \r\n            break\r\n    for i in range(len(s) - 1, -1, -1): \r\n        if (s[i] == ch): \r\n            s = \r\ns[0 : i] + s[i + 1 : len(s)] \r\n            break\r\n    return s",
  "test_list": [
    "assert remove_Occ(\"hello\", \"l\") == \"helo\"",
    "assert remove_Occ(\"abcda\", \"a\") == \"bcd\"",
    "assert remove_Occ(\"PHP\", \"P\") == \"H\""
  ]
}
```

Datasets de Evaluación

MMMU (Massive Multi-Discipline Multimodal Understanding) es un dataset de evaluación de contenidos visuales (gráficos, diagramas, imágenes médicas) para modelos multimodales tipo VLM (Vision-Language Model).

```
{
  "request_id": "M3U-9982-HOSPITAL",
  "patient_id": "PX-450",
  "status": "integrated_analysis_complete",
  "multimodal_inputs": {
    "genomic_data": {
      "type": "sequence_fasta",
      "discipline": "Genetics",
      "findings": "Mutation detected in chromosome 12 (LRRK2)",
      "confidence_score": 0.98
    },
    "medical_imaging": {
      "type": "dicom_mri",
      "discipline": "Radiology",
      "findings": "Reduced dopamine transporter activity in the striatum",
      "image_tags": ["neurodegeneration", "asymmetry"]
    }
  }
}
```

Si quieres crear tu propio
modelo para tu propio tarea

Debes crear tu
propio **benchmark**



Métricas de evaluación

BIG school

BIGSEIO

GENERAMOS
NEGOCIO

Métricas de evaluación

Cuando utilizamos modelos cerrados o modelos abiertos sobre los que hemos aplicado un proceso de fine-tuning tenemos que evaluar si los modelos ofrecen un resultado de calidad.

- Técnicas basadas en probabilidad.
- Técnicas basadas en estimulación.
- Técnicas basadas en ejecución de código.

Métricas de evaluación

Las técnicas basadas en probabilidad nos permiten estimar la secuencia de palabras más verosímil dentro de un espacio de posibilidades casi infinito, transformando el lenguaje en un problema matemático de predicción.

- ROUGE/BLEU: Comparan la superposición de palabras entre lo que escribió la IA y lo que escribió un humano.
- Exact Match (EM): Compara la respuesta dada por el modelo con la respuesta definida por el humano (estilo MMLU).



Métricas de evaluación

Las técnicas basadas en estimulación (o sampling) nos permiten explorar el espacio de respuestas del modelo para obtener resultados diversos, creativos y ajustados al contexto.

- **Zero-Shot:** Evalúa la capacidad del modelo para resolver tareas basándose exclusivamente en su conocimiento pre-entrenado, sin incluir ejemplos ni instrucciones previas durante la consulta.
- **Few-Shot:** Evalúa la agilidad del modelo para aprender patrones en tiempo real mediante la inclusión de ejemplos previos que guían el formato de la respuesta.

Métricas de evaluación

Las técnicas basadas en ejecución de código nos permiten validar la veracidad funcional y la precisión lógica de las respuestas del modelo mediante pruebas en entornos de ejecución reales (sandboxing).

- Validación de resultados: Evalúa si el código generado por el modelo se puede ejecutar y si el resultado generado es el esperado.
- Razonamiento simbólico: Evalúa si el código generado por el modelo se puede ejecutar pero delegando tareas matemáticas al intérprete de código.

¿Por qué necesito
evaluar mi modelo?

Métricas de evaluación

Es importante general un Golden Dataset con entre 50-100 preguntas relacionadas con tu contenido específico con el objetivo de comprobar si las respuestas de tu aplicación de IA cumplen tus expectativas.

Un Golden Dataset es un conjunto de datos que ha sido verificado, curado y etiquetado manualmente por expertos humanos para garantizar que sea 100% preciso.

Es la fuente de verdad absoluta para evaluar tu modelo.